

Analiza kolorów dominujących

Tymoteusz Siemieniuk

Sierpień 2024

1 Abstrakt

W niniejszej pracy porównano kilka popularnych algorytmów klasteryzacji, takich jak K-średnich, klasteryzacja spektralna oraz klasteryzacja hierarchiczna, pod kątem ich efektywności w wykrywaniu dominujących kolorów. Każdy z tych algorytmów oferuje różne podejścia do grupowania danych, co sprawia, że ich wyniki mogą się znacznie różnić w zależności od charakterystyki analizowanych obrazów. Dodatkowo przeprowadzono prostą analizę kolorystyczną za pomocą algorytmu PCA (analiza głównych składowych), bazującą na zbiorze 42 tysięcy obrazów reprezentujących różne nurtury artystyczne. Celem tej analizy było zidentyfikowanie dominujących trendów kolorystycznych, które pojawiały się w poszczególnych nurtach artystycznych na przestrzeni czasu.

Każdy z zastosowanych algorytmów klasteryzacji ma swoje zalety i wady, dlatego ich porównanie umożliwia ocenę, który z nich najlepiej nadaje się do tego rodzaju analizy danych wizualnych.

2 Wykrywanie dominujących kolorów

Wykrywanie dominujących kolorów na obrazie to zadanie, które ludziom przychodzi intuicyjnie, jednak stworzenie algorytmu, który zrealizuje to zadanie w zadowalający sposób, jest znacznie trudniejsze. Problemy, które mogą się pojawić w trakcie automatycznego rozpoznawania dominujących kolorów, obejmują między innymi:

- **Mnogość odcieni jednego koloru** – Wiele odcieni tego samego koloru może być rozproszonych po obrazie. Dla algorytmu mogą to być różne kolory, ale dla człowieka często stanowią one jedną kategorię, co oznacza, że powinny być traktowane jako jeden kolor dominujący.
- **Lokalna zmienność kolorów** – Obrazy często zawierają obszary, gdzie występuje wiele różnych odcieni blisko siebie, które z bliska mogą wyglądać odmiennie, ale z większej odległości są postrzegane przez ludzi jako jeden jednolity kolor.

- **Kolory dominujące kontekstowo** – Istnieją sytuacje, w których kolor wydaje się dominować w całym obrazie ze względu na jego kontekst, nawet jeśli faktycznie zajmuje tylko niewielką część przestrzeni obrazu. Dla człowieka ten kolor może przyciągać uwagę, ale dla algorytmu bazującego wyłącznie na liczebności pikseli może nie być istotny.

Przykładem tych zjawisk mogą być:

- obrazy Marka Rothko, gdzie duże powierzchnie o niewielkiej różnicy odcienni tworzą jednolity efekt,
- dzieła Vilhelma Hammershøia, w których subtelne przejścia tonacji wpływają na wrażenie wizualne,
- obrazy Claude'a Moneta, gdzie szczegóły z bliska mogą mieć wiele odcienni, ale z dalszej perspektywy są odbierane jako jednolita barwa.

Podejście, które zastosowano w tej pracy, polega na traktowaniu obrazu jako zbioru pikseli, które są punktami w trójwymiarowej przestrzeni kolorów RGB. Każdy piksel można opisać za pomocą współrzędnych w tej przestrzeni, a następnie na takim zbiorze wykonywana jest klasteryzacja, mająca na celu grupowanie podobnych punktów w kategorie reprezentujące dominujące kolory. Klasteryzację można opisać formalnie w następujący sposób:

- **Wejście:** $X_{1...n} \in \mathbb{R}^d$, gdzie n to liczba pikseli, a $d = 3$ to wymiar przestrzeni RGB. $k \in \mathbb{N}$ to liczba klastrów (czyli liczba dominujących kolorów, które chcemy wykryć).
- **Wyjście:** $f : 1, \dots, n \rightarrow 1, \dots, k$ – funkcja przyporządkowująca każdemu pikselowi X_i jego grupę (klaster), czyli określającą, do którego z k dominujących kolorów dany piksel należy.

3 Wykrywanie dominujących kolorów

Wykrywanie dominujących kolorów na obrazie to zadanie, które ludziom przychodzi intuicyjnie, jednak stworzenie algorytmu, który zrealizuje to zadanie w zadowalający sposób, jest znacznie bardziej trudne. Problemy, które mogą się pojawić w trakcie automatycznego rozpoznawania dominujących kolorów, obejmują między innymi:

- **Mnogość odcienni jednego koloru** – Wiele odcienni tego samego koloru może być rozproszonych po obrazie. Dla algorytmu mogą to być różne kolory, ale dla człowieka często stanowią one jedną kategorię, co oznacza, że powinny być traktowane jako jeden kolor dominujący.
- **Lokalna zmienność kolorów** – Obrazy często zawierają obszary, gdzie występuje wiele różnych odcienni blisko siebie, które z bliska mogą wyglądać odmiennie, ale z większej odległości są postrzegane przez ludzi jako jeden jednolity kolor.

- **Kolory dominujące kontekstowo** – Istnieją sytuacje, w których kolor wydaje się dominować w całym obrazie ze względu na jego kontekst, nawet jeśli faktycznie zajmuje tylko niewielką część przestrzeni obrazu. Dla człowieka ten kolor może przyciągać uwagę, ale dla algorytmu bazującego wyłącznie na liczebności pikseli może nie być istotny.

Przykładem tych zjawisk mogą być:

- obrazy Marka Rothko, gdzie duże powierzchnie o niewielkiej różnicy odcienni tworzą jednolity efekt,
- dzieła Vilhelma Hammershøia, w których subtelne przejścia tonacji wpływają na wrażenie wizualne,
- obrazy Claude'a Moneta, gdzie szczegóły z bliska mogą mieć wiele odcieni, ale z dalszej perspektywy są odbierane jako jednolita barwa.

Podejście, które zastosowano w tej pracy, polega na traktowaniu obrazu jako zbioru pikseli, które są punktami w trójwymiarowej przestrzeni kolorów RGB. Każdy piksel można opisać za pomocą współrzędnych w tej przestrzeni, a następnie na takim zbiorze wykonywana jest klasteryzacja, mająca na celu grupowanie podobnych punktów w kategorie reprezentujące dominujące kolory. Klasteryzację można opisać formalnie w następujący sposób:

- **Wejście:** $X_{1\dots n} \in \mathbb{R}^d$, gdzie n to liczba pikseli, a $d = 3$ to wymiar przestrzeni RGB. $k \in \mathbb{N}$ to liczba klastrów (czyli liczba dominujących kolorów, które chcemy wykryć).
- **Wyjście:** $f : 1, \dots, n \rightarrow 1, \dots, k$ – funkcja przyporządkowująca każdemu pikselowi X_i jego grupę (klaster), czyli określającą, do którego z k dominujących kolorów dany piksel należy.

Ocenę jakości klasteryzacji można dokonywać na różne sposoby, a jednym z popularnych podejść jest obliczanie średniej odległości każdego punktu (pikselu) od centrum jego klastra:

$$I(X, f) = \frac{1}{n} \cdot \sum_{i=1}^n (X_i - C_{f(i)})^2$$

gdzie $C_{f(i)} = \frac{1}{|f^{-1}(i)|} \sum_{j \in f^{-1}(i)} X_j$ to środek klastra i .

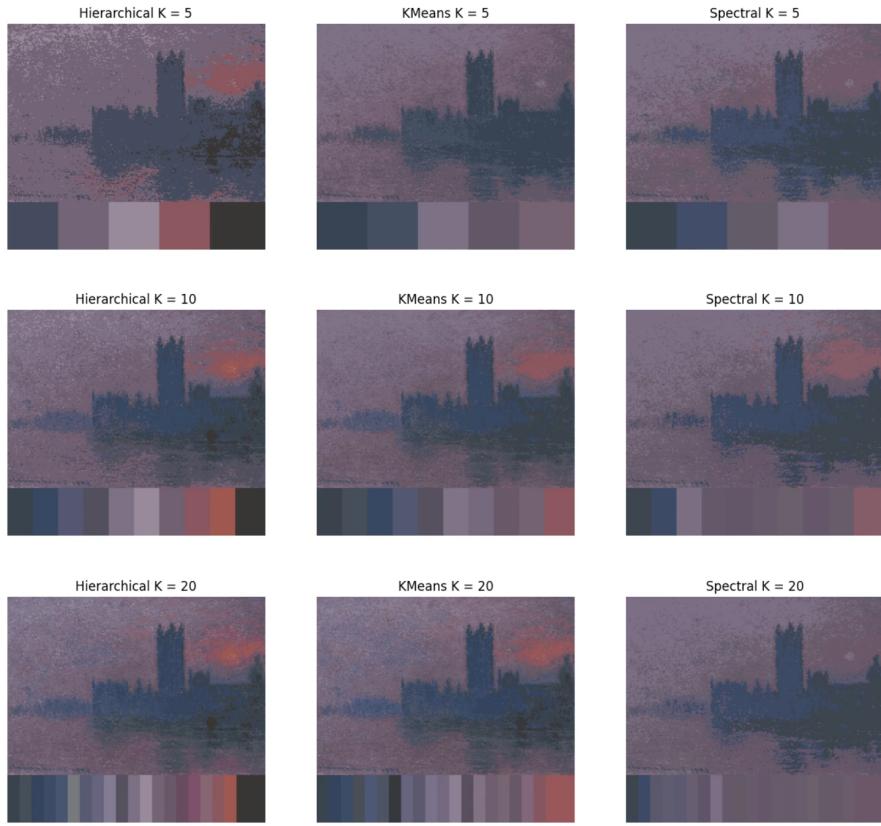
Znalezienie najlepszej klasteryzacji (tj. takiej, która daje najmniejszą wartość funkcji I dla pewnych danych wejściowych jest NP trudne [1] więc korzystam ze wspomnianych już wcześniej algorytmów aproksymacyjnych - kmeans, klasteryzacja spektralna oraz hierarchiczna.



Rysunek 1: Claude Monet - Domy parlamentu, zachód słońca (1903)

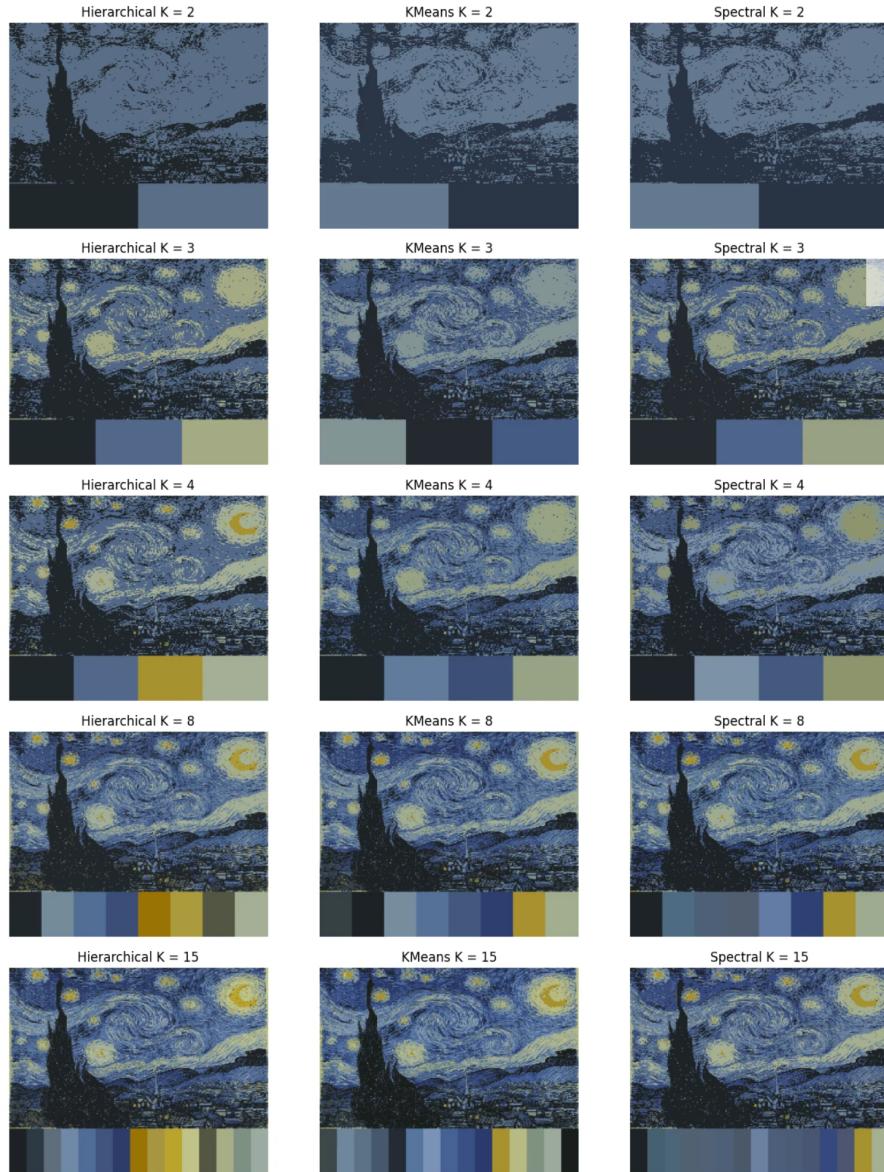
3.1 Porównanie algorytmów klasteryzacji na podstawie obrazu Monet'a

Analizę zacznę od obrazu Claude'a Monet'a - "Domy parlamentu, zachód słońca". Jest to moim zdaniem dobry obraz do analizy, ponieważ znajduje się na nim czerwone malutkie słońce, którego kolor moim zdaniem powinien się znaleźć w kilku najbardziej dominujących kolorach, pomimo swojego małego rozmiaru. Jak się jednak okaże, nie będzie to takie oczywiste dla algorytmów klasteryzacji.



Rysunek 2: Claude Monet - Domy parlamentu, zachód słońca (1903). Odpowiednio od góry: 5, 10 oraz 20 dominujących kolorów według różnych algorytmów klasteryzacji - po lewej klasteryzacja hierarchiczna, po środku k-srednich, po prawej klasteryzacja spektralna

3.2 Porównanie algorytmów klasteryzacji na podstawie obrazu Van Gogha



Rysunek 3: Vincent Van Gogh - Gwieździsta Noc (1889). Odpowiednio od góry: 2, 3, 4, 8 oraz 15 dominujących kolorów wegluk różnych algorytmów klasteryzacji - po lewej klasteryzacja hierarchiczna, po środku k-średnich, po prawej klasteryzacja spektralna

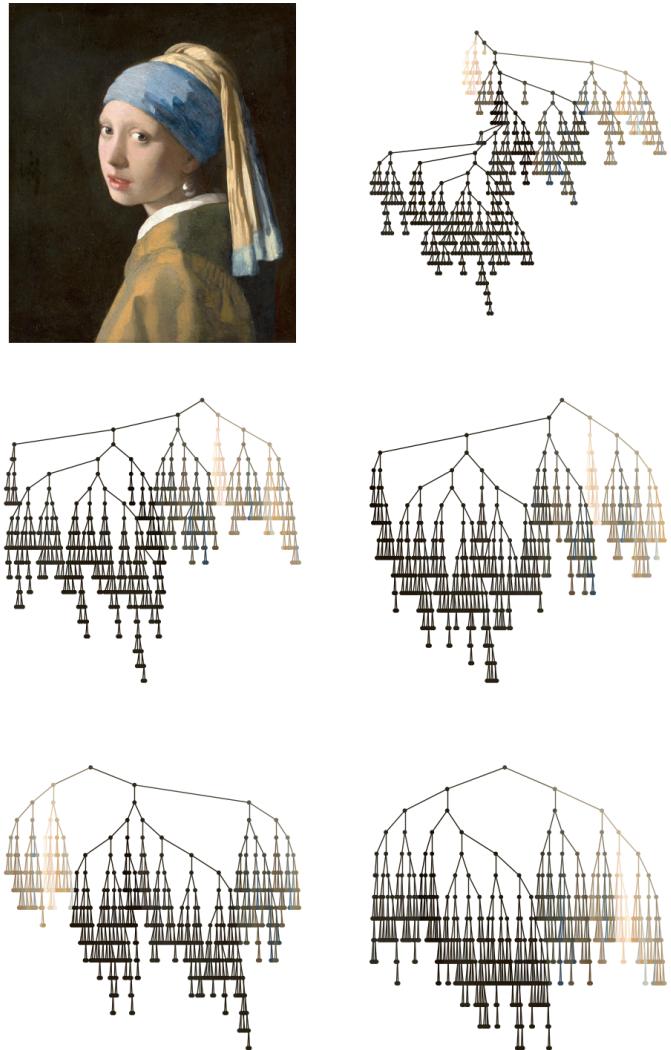
Klasteryzacja spektralna radzi sobie dość średnio z wykrywaniem dominujących kolorów na tym obrazie. Najlepiej w mojej opinii radzi sobie algorytm klasteryzacji hierarchicznej, który już dla $k = 5$ zwraca intensywny kolor słońca jako jeden z dominujących kolorów, pomimo tego, że samo słońce zajmuje stosunkowo niewielką część całego obrazu.

3.3 Końcowy algorytm

Klasteryzacja hierarchiczna moim zdaniem najlepiej radzi sobie w wykrywaniu dominujących kolorów. Dużą zaletą tego algorytmu jest to, że nie próbuje on rozbijać dużych skupisk punktów sobie bliskich na mniejsze grupy, lecz faworyzuje tworzenie nowych skupisk dla małej ilości punktów odstających (na przykład dla koloru żółtego w obrazie "Gwieździsta Noc"). Możemy to zvisualizować:



Rysunek 4: Jan Vermeer, Dziewczyna z perłą (1665-1667). 10 dominujących kolorów wg klasteryzacji hierarchicznej (łączenie pojedyńcze)



Rysunek 5: Jan Vermeer, Dziewczyna z perłą (1665-1667). Drzewa hierarchiczne dla różnych metod łączenia: pojedyńcze, centroidalne, średnie, pełne, Warda. Jak widać na rysunku, kolory które odstają od reszty (np. biały) stosunkowo późno są łączone z resztą. Ułatwia to uwzględnienie takich kolorów w końcowej liście kolorów dominujących. Po dokładniejszy opis klasteryzacji hierarchicznej odsyłam [tutaj](#).

W dalszej części pracy do analizy kolorów dominujących będę wykorzystywać klasteryzację hierarchiczną z łączeniem pojedyńczym, ponieważ uważam, że ten algorytm radzi sobie najlepiej.

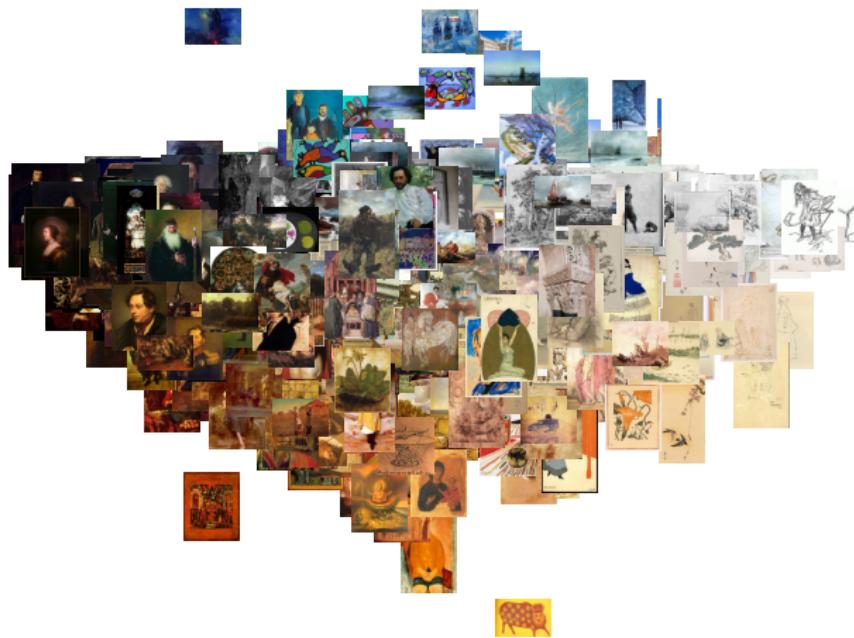
4 Ilościowa analiza trendów kolorystycznych na obrazach z różnych nurtów sztuki

Do analizy posłużył mi zbiór [WikiArt](#) - ok. 42 tysiące obrazów z różnych epok. Proces analizy tych obrazów składał się z następujących etapów:

dla danego k (1, 2, 3, 4, 5, lub 10)

1. zmapowanie każdego obrazu na k dominujących kolorów (3 k -wymiarowa przestrzeń)
2. posortowanie tych kolorów po jasności
3. zrzutowanie tak otrzymanych punktów w 3 k -wymiarowej przestrzeni na najlepszą (analiza głównych składowych - PCA) 2 wymiarową podprzestrzeń liniową.
4. przedstawienie graficzne tejże przestrzeni (obraz umieszczony tam, gdzie leży rzut jego kolorów)

Taka analiza miała na celu wykrycie trendów kolorystycznych w różnych nurtach sztuki.

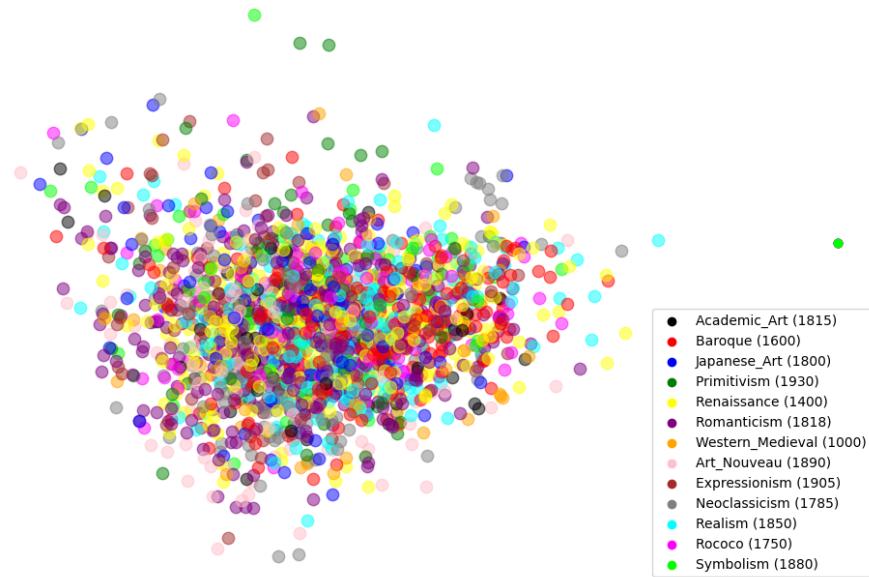


Rysunek 6: 1000 losowo wybranych obrazów najpierw zmapowanych na 1 dominujący kolor (3 wymiary), a następnie zrzutowane na 2 wymiary przez PCA

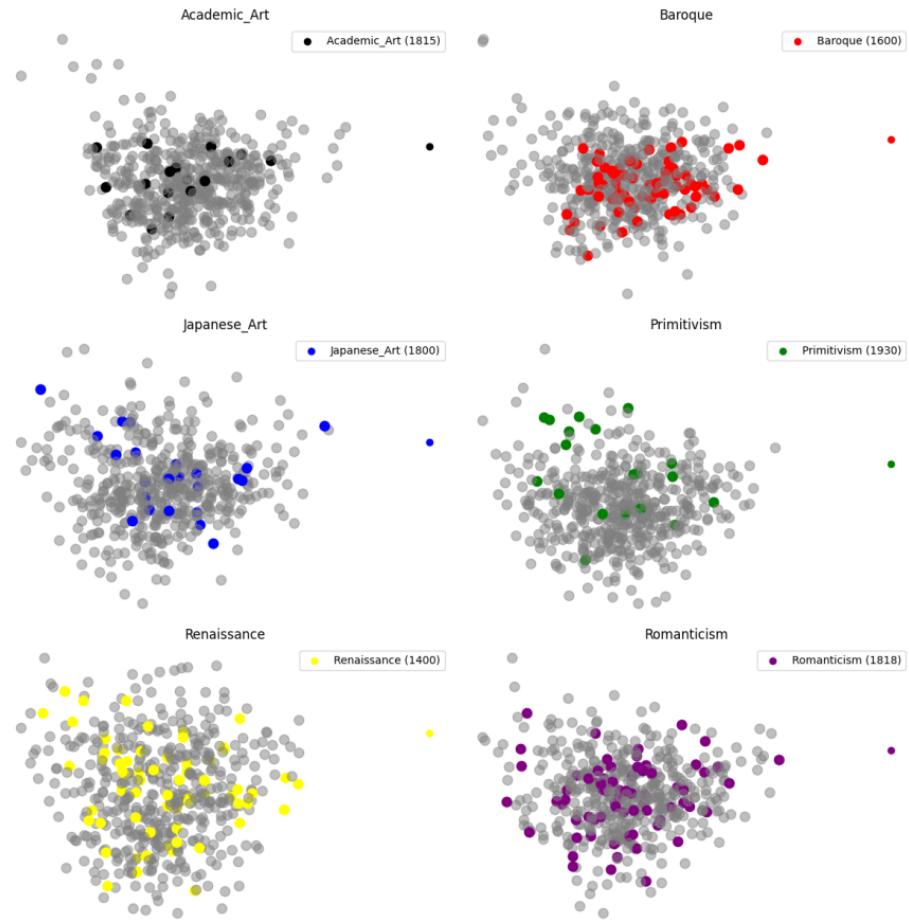


Rysunek 7: 500 losowo wybranych obrazów najpierw zmapowanych na odpowiednio - z lewej: 1, 3, 5; z prawej: 2, 4, 10 - dominujących kolorów, a następnie zrzutowane na 2 wymiary przez PCA

Wygląda to dość obiecująco, gdyż dosyć dobrze widoczne są tutaj trendy kolorystyczne. Jednak gdy przyjrzymy się dystrybucji epok na otrzymanej 2-wymiarowej przestrzeni, to wygląda to dość chaotycznie:



Rysunek 8: 2000 obrazów najpierw zmapowanych na 3 dominujące kolory, a później zrzutowane na 2-wymiarową przestrzeń przez PCA. Obrazy reprezentowane jako punkty, mające różne kolory w zależności od epoki.



Rysunek 9: 500 losowo wybranych obrazów najpierw zmapowanych na 3 dominujące kolory, a później zrzutowane na 2-wymiarową przestrzeń przez PCA. Obrazy reprezentowane jako punkty, mające różne kolory w zależności od epoki: Sztuka Akademicka, Barok, Sztuka Japońska (okres Edo), Prymitywizm, , Renesansas, Romantyzm.

Jak widać na wykresach, nie da się z nich jasno wyczytać żadnych istotnych trendów - może poza tym, że Barok znajduje się w prawym dolnym rogu, a sztuka akademicka w lewym głównym.

5 Wnioski

Poza opracowaniem dobrej metody na wykrywanie dominujących kolorów, nie udało mi się otrzymać ciekawych wyników. Być może sztuka jest zbyt skomplikowana i ciężko jest wykryć w niej trendy tak prostą analizą.

Literatura

- [1] Teofilo F. Gonzalez. On the computational complexity of clustering and related problems. 2005.